

ENTREGA 2

Comparación de Familias y Validación

Predicción del Precio de Bolsa

Mercado Eléctrico Colombiano

Aprendizaje de Máquina Aplicado · Profesor Marco Terán · Universidad EAFIT · 2026

Período train	Período test	Familias comparadas	Modelo ganador
feb 2023 – mar 2025	abr 2025 – mar 2026 (reservado)	4 familias	Random Forest HPO

Resumen Ejecutivo

Esta entrega presenta la comparación técnica entre cuatro familias de modelos para predecir el precio de bolsa diario del mercado eléctrico colombiano (horizonte: día siguiente). Se implementó un protocolo de validación temporal con TimeSeriesSplit de 5 ventanas sobre el conjunto de entrenamiento, garantizando que todas las decisiones de modelado — selección de features, HPO y comparación de familias — se tomaron sin acceso al conjunto de prueba.

El modelo ganador es **Random Forest con $n_estimators=200$, $max_depth=15$, $min_samples_leaf=1$** , con $MAE_log = 0.1847 \pm 0.0361$ en validación cruzada temporal — una reducción del 66.7% respecto al baseline trivial. Un hallazgo metodológico central es que el 90.9% de la importancia predictiva proviene del rezago de un día (lag_1), revelando que el modelo opera principalmente como predictor de persistencia. Un experimento complementario sin rezagos confirma que las condiciones estructurales del sistema ($gen_termica$, $reservas_pct$) dominan cuando se elimina la autocorrelación, conectando con los hallazgos de Villarreal & Flores (2023).

1. Introducción y continuidad con la Entrega 1

La Entrega 1 estableció el problema, el dataset y un baseline Ridge que produjo un R^2 negativo en el holdout de prueba. La interpretación fue que el cambio de régimen entre el período de El Niño (train, precio medio \$606/kWh) y el período de recuperación (test, precio medio \$188/kWh) hacía imposible la generalización con un único corte temporal y un modelo lineal.

La Entrega 1 dejó dos compromisos explícitos para esta entrega:

- **Validación por ventanas deslizantes** que capture los distintos regímenes del sistema eléctrico.
- **Evaluación de estrés_hídrico** (anteriormente llamada $tension_hidrica$) con proceso completamente libre de leakage.

Ambos compromisos se cumplen en esta entrega. El TimeSeriesSplit de 5 ventanas cubre los regímenes de amenaza del Niño, estrés hídrico, crisis de precios y recuperación. La feature $estres_hidrico = gen_termica / (reservas_pct + 0.01)$ se evalúa dentro del protocolo de validación cruzada temporal sin acceso al test.

2. Metodología

2.1 Contrato metodológico

Antes de escribir código de modelado se fijaron las siguientes decisiones. Cambiarlas después de ver resultados invalida la comparación:

Decisión	Elección	Justificación
Métrica principal	MAE en \$/kWh	Interpretable, robusta a outliers del Niño
Protocolo CV	TimeSeriesSplit 5 ventanas	Promedia sobre distintos regímenes
Pipeline	sklearn Pipeline — preprocessing dentro	Evita leakage de preprocessing
Hiperparámetros	Grids fijos antes de correr	Evita tuning oportunista
Criterio final	Menor MAE CV + parsimonia	Evita complejidad sin justificación
Horizonte	Corto plazo — día siguiente	Coherente con caso de uso del inversionista
Test	Reservado — solo en Entrega 3	Garantía de evaluación honesta

■ **MAE y no RMSE como métrica principal:** El RMSE penaliza errores grandes de forma cuadrática. Los 91 días de crisis del El Niño 2024 tienen precios hasta \$3,682/kWh — valores reales pero excepcionales. Usar RMSE llevaría el HPO a optimizar para esos días a costa del error en los 699 días normales. El MAE trata todos los errores con igual peso.

2.2 Feature engineering

Features de dominio (Entrega 1):

- **estres_hidrico** = $\text{gen_termica} / (\text{reservas_pct} + 0.01)$: captura el umbral crítico donde reservas bajas y alta térmica disparan el precio de forma no lineal.
- **efecto_solar_demanda** = $\text{demanda_pico} - \text{demanda_min}$: captura el duck curve — impacto de la solar en la demanda neta ($r=0.54$ con gen_solar).
- **gen_renovable** = $\text{gen_hidro} + \text{gen_solar} + \text{gen_eolica}$: generación limpia total que desplaza térmica.

Rezagos temporales (nuevos en Entrega 2):

- **lag_1**: precio de ayer — captura la inercia del mercado
- **lag_7**: precio de hace 7 días — captura patrón semanal
- **lag_30**: precio de hace 30 días — captura contexto mensual

Los rezagos se calcularon con `shift()` sobre el train ordenado por fecha antes del split. Los primeros 30 días con NaN se eliminaron, dejando 760 observaciones para modelado.

2.3 Protocolo de validación — TimeSeriesSplit

El K-Fold clásico no aplica para series de tiempo — mezcla el tiempo aleatoriamente permitiendo que el modelo aprenda del futuro para predecir el pasado (leakage temporal). El TimeSeriesSplit garantiza que en cada fold la validación siempre es posterior al train.

Fold	Período validación	Días	Precio medio real	Condición del sistema
1	jul–nov 2023	126	\$765/kWh	Amenaza El Niño — precios subiendo
2	nov 2023–mar 2024	126	\$578/kWh	Transición — precios variables
3	mar–jul 2024	126	\$438/kWh	Embalses en mínimos — estrés hídrico
4	jul–nov 2024	126	\$989/kWh	Crisis El Niño — pico de precios
5	nov 2024–mar 2025	126	\$488/kWh	Inicio recuperación

2.4 Familias de modelos comparadas

Familia	Modelo	Justificación
Baseline trivial	DummyRegressor (media train)	Define el piso mínimo que cualquier modelo debe superar
Baseline serio	Ridge $\alpha=1.0$	Referencia lineal — si RF no supera a Ridge, la complejidad no se justifica
Árboles (bagging)	Random Forest	Captura umbrales, discontinuidades e interacciones no lineales
Árboles (boosting)	Gradient Boosting	Corrige errores secuencialmente — captura patrones más finos

■ **¿Por qué no KNN ni SVM?** KNN predice por vecindad en el espacio de features, pero en series de tiempo el contexto temporal importa más que la similitud de features. SVM-regresión tiene hiperparámetros (C , γ) muy sensibles en series de tiempo y es computacionalmente costoso. RF y GBM dan mejor balance.

2.5 HPO — optimización de hiperparámetros

La búsqueda se realizó con RandomizedSearchCV dentro del TimeSeriesSplit ($n_iter=20$). El test no se usó en ninguna etapa del HPO.

Modelo	Hiperparámetro	Valores explorados
Random Forest	n_estimators	100, 200, 300
Random Forest	max_depth	5, 10, 15, None
Random Forest	min_samples_leaf	1, 5, 10
Gradient Boosting	n_estimators	100, 200, 300
Gradient Boosting	learning_rate	0.01, 0.05, 0.1, 0.2
Gradient Boosting	max_depth	3, 5, 7

2.6 Configuración experimental completa

La siguiente tabla resume todos los experimentos realizados. Todos usaron SEED=42, TimeSeriesSplit $n_splits=5$ y neg_mean_absolute_error como scoring.

Exp	Modelo	Tipo	Comb.	MAE_log CV	± std	Tiempo (s)
E1	Dummy (media train)	Baseline trivial	1	0.5549	0.1725	<1
E2	Ridge $\alpha=1.0$	Baseline lineal	1	0.5364	0.7213	<1
E3	Random Forest inicial	Bagging	1	0.1862	0.0358	1.6
E4	Gradient Boosting inicial	Boosting	1	0.2138	0.0392	0.9
E5	Random Forest HPO	Bagging + HPO	20/36	0.1847	0.0361	46.9
E6	Gradient Boosting HPO	Boosting + HPO	20/36	0.2048	0.0552	51.6
E7	RF sin rezagos (interpret.)	Experimento interpret.	1	0.3964	0.1938	2.6

E5 y E6: RandomizedSearchCV con $n_iter=20$ sobre 36 combinaciones posibles. E7 es un experimento interpretativo — no compite por el test. Total: 7 experimentos, 45 combinaciones evaluadas, ~104 segundos de cómputo.

3. Resultados

3.1 Comparación de modelos

Modelo	MAE_log CV	± std	Mejora vs Dummy
Dummy (media train)	0.5549	0.1725	—
Ridge $\alpha=1.0$	0.5364	0.7213	-3.3%
Random Forest inicial	0.1862	0.0358	-66.4%
GBM inicial	0.2138	0.0392	-61.5%
Random Forest HPO	0.1847	0.0361	-66.7%
GBM HPO	0.2048	0.0552	-63.1%

Mejores hiperparámetros: Random Forest — $n_estimators=200$, $max_depth=15$, $min_samples_leaf=1$. Gradient Boosting — $n_estimators=100$, $max_depth=5$, $learning_rate=0.1$.

■ **Observación clave:** Ridge no mejora al Dummy (diferencia de 0.0185 dentro del ruido de validación). Confirma que la relación precio-variables del sistema no es lineal. RF y GBM superan ampliamente los baselines. La diferencia RF HPO vs GBM HPO (0.0201) es mayor que una std del ganador (0.0361) — diferencia estadísticamente significativa.

3.2 Error por fold — modelo ganador (RF HPO)

Fold	Período	MAE_log	Precio medio real	Condición
1	jul–nov 2023	0.1838	\$765/kWh	Amenaza El Niño
2	nov 2023–mar 2024	0.1406	\$578/kWh	Transición
3	mar–jul 2024	0.2469	\$438/kWh	Estrés hídrico — mayor error
4	jul–nov 2024	0.1930	\$989/kWh	Crisis El Niño
5	nov 2024–mar 2025	0.1591	\$488/kWh	Recuperación — menor error
Promedio		0.1847		

El Fold 3 (estrés hídrico) tiene el mayor MAE_log (0.2469), no el Fold 4 (crisis de precios). Esto sugiere que el modelo maneja mejor los picos extremos (donde lag_1 ya es alto) que las transiciones desde precios moderados hacia la crisis — exactamente el escenario donde la anticipación tendría mayor valor.

3.3 Importancia de features

Feature	Importancia	Grupo
lag_1	90.9%	Rezago temporal
gen_termica	2.2%	Sistema eléctrico
estres_hidrico	0.8%	Feature engineered
lag_7	0.7%	Rezago temporal
efecto_solar_demanda	0.7%	Feature engineered
aportes_energia_gwh	0.6%	Sistema eléctrico
lag_30	0.5%	Rezago temporal
Resto (9 features)	3.6%	Varios

3.4 Experimento interpretativo — con rezagos vs sin rezagos

Modelo	MAE_log CV	± std
RF con rezagos (ganador)	0.1847	0.0361
RF sin rezagos (interpretativo)	0.3964	0.1938

Fold	Condición	MAE con lags	MAE sin lags	Diferencia
1	Amenaza El Niño	0.1838	0.2173	+0.0335
2	Transición	0.1406	0.4531	+0.3125
3	Estrés hídrico	0.2469	0.4749	+0.2280
4	Crisis El Niño	0.1930	0.6881	+0.4951
5	Recuperación	0.1591	0.1489	-0.0102 ← sin lags gana

■ **Hallazgo del Fold 5:** En recuperación el modelo sin rezagos es marginalmente mejor (-0.0102). Cuando el precio baja rápidamente, lag_1 introduce sesgo hacia arriba — recuerda los precios altos de la crisis. El modelo estructural generaliza mejor en ese cambio de régimen. Sin rezagos, gen_termica domina con 70.5% — confirmando el hallazgo de Villarreal & Flores (2023): las condiciones hidrológicas son los drivers estructurales del precio.

4. Discusión Técnica

4.1 ¿Qué modelos se compararon y por qué?

Se compararon cuatro familias: Dummy (benchmark mínimo), Ridge (baseline lineal serio), Random Forest y Gradient Boosting. La elección de RF y GBM se justifica por la naturaleza no lineal del problema — el umbral crítico de reservas no puede ser capturado por un modelo lineal. KNN y SVM se descartaron por limitaciones específicas para series de tiempo con cambios de régimen.

4.2 ¿Cómo se evitó el data leakage?

Se implementaron tres capas de protección:

- **Leakage temporal:** TimeSeriesSplit garantiza que en cada fold la validación siempre es posterior al train. K-Fold clásico fue descartado explícitamente.
- **Leakage de preprocessing:** StandardScaler y SimpleImputer encapsulados dentro del sklearn Pipeline — aprenden solo con el fold de train, nunca con datos de validación.
- **Leakage de decisión:** HPO y selección del modelo ganador exclusivamente sobre train con TimeSeriesSplit. test_energia.csv no se importó en este notebook.

4.3 ¿Cuál familia parece más prometedora?

Random Forest es la familia más prometedora, con las siguientes reservas:

- **A favor:** mejor MAE_log CV (0.1847 ± 0.0361), estabilidad entre folds (std más baja que GBM), capacidad demostrada para distintos regímenes.
- **Reserva principal:** el modelo opera como predictor de persistencia (lag_1 = 90.9%). Funciona bien en condiciones estables pero puede introducir sesgo en cambios de régimen — especialmente en la recuperación post-Niño, que es el período del test.

4.4 ¿Qué limitaciones siguen abiertas?

Limitación	Descripción	Impacto
Dominancia de lag_1	El modelo captura principalmente autocorrelación, no condiciones estructurales.	Sesgo en cambios de régimen. La Entrega 3 explorará modelo híbrido.
Cambio de régimen train/test	Train: precio medio \$606/kWh. Test: \$188/kWh.	Fold 5 es el proxy más cercano al test — MAE_log=0.1591, señal positiva.
No estacionariedad solar	gen_solar creció ~5x entre 2023-2026 por nueva capacidad instalada.	El modelo puede subestimar el efecto solar en el test.
demanda_pico sin documentación	Interpretación como duck curve es estadística (r=0.54), no documental.	Riesgo de interpretación incorrecta de la variable.

5. Decisión Provisional y Registro Pre-test

Modelo candidato para la Entrega 3: Random Forest con n_estimators=200, max_depth=15, min_samples_leaf=1.

Justificación: mejor MAE_log CV promedio (0.1847) con diferencia estadísticamente significativa respecto al segundo candidato GBM (0.2048). Diferencia de 0.0201 mayor que 0.0361 (una desviación estándar del ganador).

Campo	Valor
Modelo	Random Forest
n_estimators	200
max_depth	15
min_samples_leaf	1
Features	16 (10 sistema + 3 engineered + 3 rezagos)
Target	log(precio_bolsa_kwh)
MAE_log CV promedio	0.1847
MAE_log CV std	0.0361
Test usado en selección	No
Test usado en HPO	No

■ **Compromiso pre-test:** El archivo test_energia.csv se evalúa UNA SOLA VEZ en la Entrega 3. Este registro no se modifica después de ver el test.

6. Conclusiones

El cambio de régimen identificado en la Entrega 1 como causa del R^2 negativo del baseline Ridge queda parcialmente resuelto con modelos no lineales y validación temporal. Random Forest reduce el MAE en un 66.7% respecto al baseline trivial, con un error estable entre los distintos regímenes del sistema eléctrico colombiano.

El hallazgo metodológico más importante de esta entrega es la dualidad entre el modelo de persistencia (con rezagos, lag_1 domina) y el modelo estructural (sin rezagos, gen_termica domina). Esta dualidad conecta con la conclusión central de Villarreal & Flores (2023): el modelo óptimo depende del horizonte de predicción.

La Entrega 3 evaluará el modelo ganador sobre el test reservado y explorará si un modelo híbrido o sin rezagos mejora la anticipación de cambios de régimen — el escenario más relevante para un inversionista ante la posible ocurrencia de un nuevo fenómeno El Niño en el segundo semestre de 2026.

Referencias

- Villarreal Marimon, Y.J. & Flores San Martín, L.A. (2023). *Predicción del precio de la energía eléctrica en Colombia mediante un enfoque de machine learning*. Tesis de grado, MAF, Universidad EAFIT.
- Terán, M. (2026). *Notas de clase — Sesiones 03 y 04: Modelos lineales, validación y selección de modelos*. Aprendizaje de Máquina Aplicado, Universidad EAFIT.
- XM S.A. E.S.P. (2026). *Históricos Sinergox*. <https://sinergox.xm.com.co>